

데이터사이언스전공
202404252 원종우
202404185 구은완

트와이스 노래가사 분석 & 모델링



응용머신러닝 기말과제

INDEX

발표 목차


1

주제 개요




2

데이터 구조



3

진행과정



4

주요 코드



5

분석 결과



6

시각화 결과



01

주제 개요



The screenshot shows the Kaggle dataset page for 'TWICE Korean singles lyrics' by JC PERALTA. The page includes a search bar, a sidebar with navigation options (Create, Home, Competitions, Datasets, Models, Benchmarks, Game Arena, Code, Discussions, Learn, More, Your Work, VIEWED, TWICE Korean single..., Steam Review&Game..., View Active Events), and a main content area. The main content area displays the dataset title, a description, and tabs for Data Card, Code (3), Discussion (0), and Suggestions (0). The 'About Dataset' section is expanded, showing the data source and how it was obtained. The 'Usability' section shows a score of 10.00. The 'License' section shows 'Other (specified in description)'. The 'Expected update frequency' section shows 'Annually'. The 'Tags' section shows 'Music', 'Popular Culture', and 'Korea'.

What is the data?
This dataset contains all TWICE Korean single lyrics from 2015-2022. The included songs are Like Ooh Ahh (2015), Cheer Up (2016), TT (2016), Heart Shaker (2017), Knock Knock (2017), Likey (2017), Dance The Night Away (2018), What Is Love (2018), Yes or Yes (2018), Fancy (2019), Feel Special (2019), More&More (2020), I Can't Stop Me (2020), Cry For Me (2020), Alcohol Free (2021), Scientist (2021) and Talk that Talk (2022)

How was the data obtained?
Since TWICE is pretty popular, I expected to find a table somewhere in the web that contains this kind of data but unfortunately, I haven't found any so I decided to make my own. This would normally be a transcription exercise that would take up a lot of time and energy, but I think I found a way to lazily do it with help of some programming.

1.
First, I obtained timing data from subtitles (.srt) of TWICE music videos in Youtube. This is simple—we just need to extract the .srt subtitle file from the video (there are lots of online applets for this!) and read the file in python to get the start and end of each subtitle line.

<https://www.kaggle.com/datasets/jcacperalta/twice-korean-singles-lines>

> 데이터 구조

2015~2022까지 트와이스 타이틀곡(곡명·연도)에서 특정 구간의 가사, 시작/끝 시각, 보컬 멤버, 구간 길이를 담은 라인 단위 가사 데이터

```
df = pd.read_csv('../data/twice_korean_singles_lines.csv')
df.head()
```

[3] ✓ 0.0s

...

	start_time	end_time	lyric	vocal1	vocal2	duration	song_name	song_year
0	00:00:13,293	00:00:15,108	modu nareul gajigo	Nayeon	NaN	1.815	LikeOohAhh	2015
1	00:00:15,108	00:00:16,687	maeil gaman an dujo	Nayeon	NaN	1.579	LikeOohAhh	2015
2	00:00:16,687	00:00:18,327	naega neomu yeppeujo	Momo	NaN	1.640	LikeOohAhh	2015
3	00:00:18,327	00:00:20,116	na ttaemune da himdeuljo	Momo	NaN	1.789	LikeOohAhh	2015
4	00:00:20,116	00:00:21,705	eodil geotgo isseodo	Nayeon	NaN	1.589	LikeOohAhh	2015

start_time: 멤버별 파트 시작 시간

end_time: 멤버별 파트 종료 시간

lyric: 가사

vocal1: 멤버1

vocal2: 멤버2 (함께 부르는 파트에 해당)

duration: 파트 별 시간

song_name: 곡 이름

song_year: 곡 발매년도

> 진행 과정

End to End 방법 사용


01



데이터 분석

11주차에 배운
텍스트 데이터분석

02



모델 설계 및 제작

Apriori 알고리즘을 통한
노래별 단어 패턴이 특정
멤버에게 얼마나
집중되는지 분석

03



결론 도출 및 시각화

곡별 자주 반복되는 단어
막대그래프, 워드클라우드

> 주요 코드 (곡별 단어 빈도 계산 로직)

곡별로 가사를 합치고 → 전처리 → 불용어 제거 → 단어 빈도 계산

```
song_groups = df.groupby("song_name")

song_word_freq = {} # 곡별 단어 빈도 저장

for song, group in song_groups:
    lyrics = " ".join(group["lyric"].astype(str))
    lyrics = clean_text(lyrics)

    words = lyrics.split()
    words = [w for w in words if w not in stop_words and len(w) > 1]

    freq = Counter(words)
    song_word_freq[song] = freq
```


> 주요 코드 (트랜잭션 생성)

텍스트 기반 데이터를 연관 규칙 학습에 적합한 트랜잭션 형태로 변환

```
# 데이터를 Apriori 입력 형식으로 변환
transactions = []

for _, row in df.iterrows():
    words = row['clean_lyric'].split()

    # 빈 단어 제거
    words = [w for w in words if len(w) > 0]


    # 멤버 이름을 하나의 "항목"으로 추가
    words.append(f"VOCAL_{row['vocal1']}")

    transactions.append(words)
```

가사단어



부른멤버



하나의 트랜잭션으로 구성

> 주요 코드 (Apriori 모델 및 연관 규칙 생성)

Apriori 알고리즘을 적용하여 가사 단어와 멤버 간의 관계 규칙을 도출 (특정 단어가 가사에 등장하면 → 특정 멤버가 VOCAL 파트를 맡았을 확률이 높다)

```
te = TransactionEncoder()
te_arrays = te.fit(transactions).transform(transactions)
df_tx = pd.DataFrame(te_arrays, columns=te.columns_)

freq_items = apriori(df_tx, min_support=0.01, use_colnames=True)
rules = association_rules(freq_items, metric="lift", min_threshold=1.0)

rules_to_vocal = rules[rules['consequents'].apply(lambda x: any('VOCAL_' in i for i in x))]
```

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	representativity
1	(you)	(VOCAL_Dahyun)	0.087079	0.091760	0.010300	0.118280	1.289006	1.0
2	(baby)	(VOCAL_Jihyo)	0.036517	0.172285	0.010300	0.282051	1.637124	1.0
5	(deo)	(VOCAL_Jihyo)	0.038390	0.172285	0.010300	0.268293	1.557264	1.0
7	(i)	(VOCAL_Jihyo)	0.074906	0.172285	0.014045	0.187500	1.088315	1.0
9	(me)	(VOCAL_Jihyo)	0.065543	0.172285	0.015918	0.242857	1.409627	1.0

> 분석결과 (Apriori 모델 멤버관련 규칙 Top 5)

멤버 관련 규칙 TOP 5

	antecedents	consequents	antecedent support	consequent support \
11	(nal)	(VOCAL_Jihyo)	0.032772	0.172285
3	(baby)	(VOCAL_Jihyo)	0.036517	0.172285
14	(i)	(VOCAL_Nayeon)	0.074906	0.170412
5	(deo)	(VOCAL_Jihyo)	0.038390	0.172285
8	(me)	(VOCAL_Jihyo)	0.065543	0.172285

	support	confidence	lift	representativity	leverage	conviction
11	0.010300	0.314286	1.824224	1.0	0.004654	1.207085
3	0.010300	0.282051	1.637124	1.0	0.004008	1.152889
14	0.020599	0.275000	1.613736	1.0	0.007834	1.144259
5	0.010300	0.268293	1.557264	1.0	0.003686	1.131211
8	0.015918	0.242857	1.409627	1.0	0.004626	1.093209

	zhangs_metric	jaccard	certainty	kulczynski
11	0.467130	0.052885	0.171558	0.187034
3	0.403923	0.051887	0.132614	0.170917
14	0.411115	0.091667	0.126072	0.197940
5	0.372134	0.051402	0.115992	0.164038
8	0.310975	0.071730	0.085262	0.167624



지효(VOCAL_Jihyo)

- “nal”, “baby”, “deo”, “me” 같은 단어와 가장 강한 연관
- 강한 보컬 포지션답게 감정 표현 단어/핵심 키워드에 자주 배치됨




나연(VOCAL_Nayeon)

- 영어 1인칭 “I”와 강한 연관
- 밝고 선두에서 이끄는 스타일의 파트 배정 패턴이 반영된 듯

> 시각화 결과 (Apriori 모델 시각화 networkx)


Association Rule Network Graph



- 굵은 선일수록 특정 단어가 등장할 때 해당 멤버가 보컬 파트를 맡을 확률이 높음을 의미
- 지효는 me, you, baby와 같은 감정 표현 단어와 강하게 연결되어 있음
- 나연은 i, the, away 등 영어 중심 단어들과 연관성이 두드러짐
- 전체적으로 TWICE 가사의 멤버별 파트 배정 패턴이 시각적으로 드러나는 구조 (signal-bonae, dance-the-night-away)

> 시각화 결과 (곡별 중복단어 top20 nltk)

Top 15 Words - KnockKnock



Knock Knock을 기준으로
Knock이라는 단어가 80회 이상
중복된 것을 확인



> kaggle 제출

<https://www.kaggle.com/code/wonjongwoo/twice-song-analysis>

Kaggle: Your Home for Data Science - twice song analysis

Search

WONJONGWOO · 10M AGO · 11 VIEWS

twice song analysis

Notebook Input Output Logs Comments (0) Settings

In [1]:

```
import pandas as pd
import matplotlib.pyplot as plt
import networkx as nx
import re
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori, association_rules
```

In [2]:

```
df = pd.read_csv("/kaggle/input/twice-korean-singles-lines/twice_korean_singles_lines.csv")
```

In [3]:

```
# Pre processing
def clean_text(text):
    text = text.lower()
```

Version 2 of 2

Runtime
▶ 38s

Input
DATASETS
twice-korean-singles-lines

Tags
Add Tags

Language
Python

THANK YOU

감사합니다

프로젝트에 사용된 소스코드와 데이터는 아래 qr코드를 통해 확인하실 수 있습니다.

